

Offline Coding

CHECK24 Berlin – Recruiting

Challenge: Klassifikations-Algorithmus für E-Mail-Sortierung

Problemstellung

In Firmen verbringen Mitarbeiter oftmals viel Zeit mit der Sortierung von eingehenden E-Mails in Subordner des Posteingangs, um zukünftig E-Mails schnell wiederzufinden. E-Mail Clients, wie z.B. Outlook, bieten hierfür bereits regelbasierte automatische Zuordnungen an. Dennoch beruhen diese lediglich auf sehr einfachen Regeln, wie z.B. der Zuordnung auf Basis eines bestimmten Absenders oder eines expliziten Themas. Oftmals sind diese einfachen Regeln nicht ausreichend und daher sortieren Mitarbeiter weiterhin einen großen Anteil ihrer E-Mails manuell.

Daher besteht der Bedarf durch Klassifizierungs-Methoden aus dem Machine Learning die zugrundeliegenden Strategien, welche Mitarbeiter nutzen, um manuell E-Mails in Subordner zu sortieren zu identifizieren und auf der Basis ein intelligentes automatische Klassifizierungs-Modell zu entwickeln und somit die manuelle Arbeit eines jeden Mitarbeiters zu reduzieren.

In dieser Aufgabe hast Du einen Auszug aus einem Datensatz von ca. 450.000 echten E-Mails und deren jeweiligen (manuellen) Zuordnung in einen Subordner. Nutze diese als Basis um die wesentlichen Treiber für eine Zuordnung einer bestimmten E-Mail in einen Subordner zu identifizieren.

Aufgabenstellung

Erarbeite auf Basis des Datensatzes ein intelligentes automatisches E-Mail-**Klassifizierungs-Modell**, mit welchem der passende Unterordner (bzw. Ordner, falls nicht vorhanden) geschätzt wird.

Dokumentiere in Stichpunkten, wie Du diese Aufgabe angegangen bist, welche Analyseschritte Du durchgeführt hast und wie Du Deine Ergebnisse bewertest. Deine Dokumentation sollte es einer informierten dritten Person ermöglichen, Deine Argumentation und Vorgehensweise zu verstehen. Bitte verwende python und die entsprechenden libraries, wie z.B. scikit-learn, und nutze zur Dokumentation Deiner Lösung (Plots, Tabellen, Source Code) ein Jupyter notebok. Das Layout und die Formatierung der Dokumentation werden nicht bewertet.

Versuche möglichst, die Aufgabe bis hin zum trainierten und evaluierten Modell zu lösen. Es empfiehlt sich daher, die entsprechenden Teilschritte auf diesem Weg in der in Anbetracht der Zeitvorgaben gebotenen Tiefe zu bearbeiten. Solltest Du nicht vollständig fertig werden, gib bitte einen kurzen Ausblick auf die noch fehlenden Schritte und wie Du sie angegangen wärst.

Notiz: Bitte siehe zur Lösung dieses Problems von Methoden aus dem Deep Learning Bereich, wie z.B. Convolutional Neural Networks, ab.

Datensatz

Dieser Datensatz ist ein Auszug des Enron E-Mail Datasets. Dieser enthält ca. 450.000 E-Mails von über 150 Enron Mitarbeitern und die jeweilige Zuordnung einer jeden E-Mail in einen Subordner des Posteingangs. Dieser Datensatz wurde im Rahmen der Untersuchung des Enron-Skandals verfügbar und ist nun allgemein für wissenschaftliche Untersuchungen freigegeben. Da aufgrund der Größe des Datensatzes allein der Import aller Daten zu viel Zeit in Anspruch nehmen würde, empfehlen wir Dir, für die Analyse nur eine Stichprobe (z.B. 10% der E-Mails) der E-Mails zu nutzen. Du kannst auch gerne eine der zur Verfügung gestellten Auszüge aus dem Datensatz nutzen:

Das Passwort lautet jeweils „c24“.

- Link zum gesamten Datensatz (etwa 1,3 GB, gezippt 386MB). Zum Öffnen dieser Datei ist ein Download notwendig:
<https://www.dropbox.com/scl/fi/yfuldb9z1wechg3c52b67/emails.csv.zip?rlkey=a5zpogorjvy2r8zd202lqqc64&dl=0>
- Link zu mittelgroßem Auszug des Datensatzes (etwa 150 MB, gezippt 39MB):
<https://www.dropbox.com/scl/fi/5r5wuyg06xt632mgwlnl5/emails150MB.csv.zip?rlkey=c6gvcvpt3o1914jux7cail1x5&dl=0>
- Link zu kleinem Auszug des Datensatzes (etwa 30MB, gezippt 7MB):
<https://www.dropbox.com/scl/fi/c30copwlkjbih6yxon73/emails30MB.csv.zip?rlkey=k5hirs1huiovsqj48t4pxhet&dl=0>

Beschreibung des Datensatzes

- Die Ablage der E-Mails in dem Datensatz entsprechen folgendem Schema:
 - Username / Ordner inkl. Subordner / E-Mail (durchnummeriert)
- Innerhalb einer jeden E-Mail sind folgende relevanten Parameter vorhanden
 - Message-ID: *Unique Identifier einer E-Mail*
 - o Date: *Zeitpunkt der Versendung*
 - o From: *Absender der E-Mail*
 - o To: *Empfänger der E-Mail*
 - o Subject: *Betreff der E-Mail*
 - o Cc: *Zusätzliche Empfänger welche in CC (Carbon Copy) genommen wurden*
 - o Body der E-Mail: *Nachricht an den Empfänger*